

Misalignment-eliminated warping image stitching method with grid-based motion statistics matching

Zaifeng Shi ¹
 Pumeng Wang ¹
 Qingjie Cao ¹
 Cheng Ding ¹
 Tao Luo ¹

Resumo: O alinhamento de imagens é um dos principais desafios do *image stitching* na geração de mosaicos. Limitadas pela precisão de *matching* e pela capacidade de deformação, as principais abordagens atuais frequentemente apresentam erros evidentes de costura ao processar cenas com grande paralaxe. Para solucionar essa lacuna, este estudo analisa uma arquitetura de *stitching* baseada em *misalignment-eliminated warping*. A metodologia integra uma abordagem de *matching coarse-to-fine* — combinando os algoritmos *Oriented FAST and Rotated BRIEF* (ORB) e *grid-based motion statistics* (GMS) — para garantir um conjunto robusto de correspondências corretas (*inliers*) para o *warping* subsequente. Em seguida, uma *local homography* ancorada por uma *global similarity transformation constraint* é empregada para deformar as imagens e estabelecer o alinhamento inicial. Para erradicar os vieses de projeção remanescentes do *local warping*, aplica-se uma etapa de *post-processing* elástico utilizando *thin plate spline* (TPS). A análise das avaliações qualitativas e quantitativas em cenários desafiadores comprova que o método elimina os desalinhamentos com elevada precisão, preservando simultaneamente a aparência natural da cena.

Palavras-chave: Image stitching. Image alignment. Local warping. Image registration.

1 Introdução

Métodos tradicionais, que usam transformações homográficas globais ou locais (como o APAP), possuem limitações significativas: dependem de algoritmos de detecção de características (como SIFT e RANSAC) que frequentemente falham em regiões com pouca textura ou texturas repetitivas, e têm dificuldade em lidar com distorções de perspectiva e deformações onde a profundidade da cena muda drasticamente. Para resolver esses problemas, o artigo [1] apresenta um método focado em alcançar alta precisão geométrica por meio das seguintes inovações:

- Registro de imagens mais preciso (ORB + GMS): transforma restrições de suavidade de movimento em medidas estatísticas para filtrar falsos positivos, entregando uma quantidade muito maior e mais confiável de correspondências de pontos entre as imagens.
- Pós-processamento com deformação não-rígida (TPS): age compensando os vieses de projeção nas áreas de sobreposição de forma adaptativa, eliminando os desalinhamentos finos e "fantasmas" que as homografias locais não conseguem resolver
- Correção de distorção de perspectiva: integra uma restrição de similaridade global durante a costura local para evitar que as áreas da imagem que não se sobrepõem sofram distorções de perspectiva, garantindo que o mosaico final tenha uma aparência perfeitamente natural

Segundo os autores, a combinação de dados de correspondência de alta qualidade (via ORB e GMS) somada a um pós-processamento de deformação flexível (via TPS) consegue alinhar as imagens com precisão, superando a qualidade visual das principais abordagens atuais. Os experimentos realizados em conjuntos de dados públicos

¹School of Microelectronics, Tianjin University, Tianjin, China
 {shizaifeng@tju.edu.cn}

validaram que essas três inovações conferem ao método, maior precisão de alinhamento. O algoritmo consegue eliminar os vieses de projeção e gerar uma costura adequada (invisível) e de aparência natural. No entanto, para alcançar essa alta fidelidade visual e correção geométrica nas emendas, o método sacrifica a eficiência computacional, não apresentando vantagens de velocidade e exigindo maior tempo de processamento quando comparado a outros métodos da literatura.

2 Trabalhos relacionados

2.1 Registro de imagens

O registro de imagens é a etapa inicial e fundamental para a costura de imagens (image stitching). Ele consiste em identificar e conectar os mesmos pontos de interesse em duas ou mais imagens diferentes. Essa etapa fornece todo o suporte de dados necessário para que o algoritmo consiga calcular a sobreposição e a deformação correta das imagens. A qualidade do mosaico final depende diretamente da precisão e do sucesso desse registro. Os métodos atuais mais utilizados para o registro baseiam-se em características (features) da imagem e são divididos em duas subetapas principais: a extração e a correspondência (matching) dessas características:

- Extração de Características:
 - Evolução: extração focada em detectar cantos nas imagens (Harris e FAST), mas eles forneciam informações limitadas.
 - O SIFT e seus problemas: Para obter dados mais ricos, surgiu o descritor SIFT. Contudo, gera pontos esparsos que não funcionam bem em áreas com texturas repetitivas ou fracas.
 - Soluções binárias e Deep Learning: descritores binários, como o algoritmo ORB, que conseguem calcular uma quantidade muito maior e mais densa de pontos em um tempo menor. Descritores baseados em Deep Learning, como o UDBD, para tentar superar limitações geométricas.
- Correspondência de Características (Matching):
 - Matching Grosso (Coarse): após extrair os pontos das duas imagens, o algoritmo faz uma comparação de similaridade básica, como a de Força Bruta (Brute Force), gerando falsos positivos.
 - Matching Refinado (Fine) e a Limitação do RANSAC: em cenas não-planares (com múltiplas homografias/profundidades), ele frequentemente apaga correspondências corretas e mantém as erradas.
 - A Solução com Grid-based Motion Statistics (GMS): analisa a vizinhança de cada ponto para checar a suavidade estatística do movimento. Isso permite que ele ignore as falsas correspondências sem ser prejudicado por cenas de múltiplas profundidades, convertendo dezenas de marcações brutas em correspondências altamente precisas

O artigo conclui ser ideal usar a combinação rápida e densa do ORB com a filtragem inteligente do GMS para resolver problemas difíceis de paralaxe e textura.

2.2 Deformação Espacialmente Variável (Spatially-varying warping)

No image stitching clássico, os algoritmos tentam encontrar uma única equação matemática, chamada de homografia global, para alinhar e costurar duas imagens. Essa abordagem assume que a cena fotografada é perfeitamente plana ou que a câmera apenas rotacionou em seu próprio eixo. No entanto, no mundo real e em cenas com grande variação de profundidade (alta paralaxe), usar uma regra única entorta os objetos, gera duplicações (ghosting) e destrói o alinhamento. Em vez de aplicar uma transformação rígida para a foto inteira, a técnica de *spatially-varying warping* divide a imagem em várias partes (como uma malha ou grade) e calcula múltiplas matrizes de homografia, uma para cada região local. O resultado é uma malha elástica e adaptativa. Métodos como o SPHP e o AANAP surgiram para corrigir as distorções de perspectiva que podem ocorrer nas regiões não-sobrepostas da imagem. Eles suavizam a imagem forçando uma transição gradual da transformação projetiva para uma transformação de similaridade. No entanto, eles assumem que a mudança de profundidade na cena é contínua. Em cenários mais complexos e com saltos abruptos de profundidade (como os encontrados frequentemente em agricultura ou terrenos acidentados), esses métodos não conseguem garantir a qualidade da costura.


2.3 Thin plate spline (TPS)

O Thin Plate Spline (TPS) é um modelo matemático clássico usado para deformação não-rígida. Diferente das homografias (que deformam a imagem inteira de forma rígida, como se fosse um plano inclinado), o TPS permite que a imagem seja distorcida de forma elástica. Ele usa pontos de controle (os inliers encontrados no matching) para "puxar" os pixels até o lugar correto, interpolando suavemente a deformação no resto da imagem para que ela não pareça artificialmente rasgada. O TPS constrói um sistema linear baseado na correspondência dos pontos de características (feature points). Ao resolver os parâmetros matemáticos, ele alinha as imagens aplicando uma deformação não-rígida e contínua. No entanto, o algoritmo exige dados de correspondência de altíssima qualidade. Ou seja, se o algoritmo de matching (como o SIFT comum) fornecer pontos com erros, o TPS vai entortar a imagem de forma significativa.

3 Métodos

Conforme ilustrado na Figura 1, a arquitetura foi desenvolvida para eliminar os erros de alinhamento que os algoritmos tradicionais de *warping* local (como o APAP, baseado em m-DLT) não conseguem resolver de forma isolada. A metodologia proposta é estruturada em quatro etapas fundamentais, mostrando-se especialmente útil para lidar com a costura de superfícies que apresentam microrrelevos e alta paralaxe local:

Figura 1: Fluxograma para o método proposto



- **Registro de Imagens Coarse-to-fine (Do Grosso para o Fino):** utiliza o algoritmo ORB para a extração rápida de um grande volume de características iniciais e, em seguida, aplica o GMS (*Grid-based Motion*

Statistics) para filtrar os erros de forma robusta, garantindo uma quantidade elevada de *inliers* precisos.

- **Warping por Homografia Local com Restrição Global:** a partir dos *inliers*, calcula as homografias locais dividindo a área de sobreposição numa malha através do cálculo m-DLT. Crucialmente, integra uma transformação de similaridade global para corrigir distorções de perspectiva nas áreas não sobrepostas da imagem.
- **Pós-Processamento com TPS (*Thin Plate Spline*):** constrói uma função de deformação não-rígida baseada nos *inliers* para calcular o deslocamento exato (*offset*) que cada pixel precisa sofrer nas direções X e Y. A imagem sofre então um micro-reajuste elástico que absorve completamente os vieses de projeção e as deformações residuais da superfície.
- **Fusão Final (*Linear Blending*):** os pixels são recombinaados utilizando uma mistura linear para fundir a área de sobreposição, suavizando as diferenças e gerando um mosaico final com uma aparência natural e sem costuras visíveis.

4 Experimentos e Análise

Para avaliar o método proposto, os autores dividiram os testes em quatro frentes principais:

- **Comparação Geral:** Avaliar a qualidade do alinhamento (de forma visual/qualitativa e matemática/quantitativa) contra outros métodos consolidados:
 - Homografia Global: Representa a matemática tradicional e rígida.
 - APAP: Representa a família das malhas de deformação local (*spatially-varying warping*).
 - SPHP e AANAP: Representam os algoritmos focados em eliminar distorções de perspectiva em áreas sem sobreposição.
 - FARSE: Representa os métodos modernos baseados em busca de emenda (*seam cutting*).
 - DIS: Representa as abordagens modernas baseadas em Inteligência Artificial (*Deep Learning*).
- **Análise de Distorção:** Provar se a restrição de similaridade global que eles adicionaram realmente reduz as distorções de perspectiva.
- **Análise por Etapas (Ablação):** Avaliar a qualidade do alinhamento isolando as fases do código, para descobrir o impacto exato da etapa de registro versus o impacto do pós-processamento de deformação elástica (o TPS).
- **Eficiência:** Comparar o custo computacional (tempo de execução) entre as técnicas.

4.1 Comparação Qualitativa


Na avaliação qualitativa da qualidade de alinhamento em cenários desafiadores com alta paralaxe, o estudo demonstra que os métodos de costura existentes (como Homografia Global, APAP, SPHP, AANAP e FARSE) falham em lidar com os vieses de projeção, resultando em desalinhamentos óbvios e efeitos fantasmas (*ghosting*) nas áreas de sobreposição. Em contrapartida, o método proposto pelos autores supera essas limitações ao combinar uma estratégia de registro de alta precisão baseada em GMS com uma etapa de pós-processamento de deformação elástica usando TPS, o que elimina com sucesso os desvios residuais e alcança um alinhamento visualmente perfeito e preciso nas emendas.

4.1.1 Comparação qualitativa da qualidade do alinhamento

Na avaliação qualitativa da qualidade de alinhamento, ilustrada pela Figura 2 através do desafio cenário *worktable*, fica evidente a superioridade da abordagem proposta em relação aos métodos concorrentes. Enquanto a homografia global apresenta desalinhamentos óbvios devido a vieses de projeção, os métodos de *warping* local

(como APAP e AANAP) conseguem reduzir o problema, mas ainda deixam distorções residuais e um leve efeito fantasma (*ghosting*). Abordagens como o SPHP e o FARSE falham de forma ainda mais significativa, gerando duplicações severas e desalinhamentos visíveis nas áreas de sobreposição por não conseguirem lidar com a alta paralaxe. Em contraste, graças à estratégia de registro de alta qualidade (GMS) combinada com a etapa de pós-processamento elástico (TPS), o método proposto elimina por completo os desvios de projeção remanescentes, alcançando um alinhamento visualmente impecável e livre de artefatos nas regiões destacadas.

Figura 2: Comparação da qualidade de alinhamento na cena worktable. (a) Resultado da homografia global. (b) Resultado do APAP. (c) Resultado do SPHP. (d) Resultado do AANAP. (e) Resultado do FARSE. (f) Resultado do nosso método. As caixas verde, vermelha, azul e amarela em cada um dos resultados estão ampliadas e são nomeadas (I), (II), (III) e (IV), respectivamente.



4.1.2 Comparação da qualidade na perspectiva de redução de distorções

Na avaliação qualitativa para a redução de distorções em cenários complexos, os métodos tradicionais e de malha local demonstraram equilíbrio significativo. A homografia global e o APAP falharam em corrigir a distorção de perspectiva nas áreas não sobrepostas das imagens, resultando em inclinações artificiais severas nas estruturas.

Por outro lado, abordagens focadas em mitigar essa distorção de perspectiva, como SPHP e AANAP, conseguiram endireitar as imagens, mas sacrificaram a qualidade da costura, mantendo efeitos fantasmas e desalinhamentos nas áreas de sobreposição (o mesmo ocorrendo com o método FARSE). Em contrapartida, o método proposto provou ser capaz de resolver ambos os problemas simultaneamente: ao integrar uma restrição de similaridade global à malha de deformação, ele mitigou amplamente a distorção de perspectiva nas regiões sem sobreposição (preservando a aparência natural dos objetos) e, ao mesmo tempo, alcançou um alinhamento preciso e livre de ghosting nas emendas.

4.1.3 Comparação qualitativa com métodos baseados em aprendizado

Na comparação qualitativa com métodos baseados em aprendizagem profunda (deep learning), como o Deep Image Stitching (DIS), o estudo demonstra que estas abordagens ainda são insuficientes para satisfazer as necessidades das aplicações práticas. Embora o DIS consiga alinhar cenas simples com paralaxe, apresenta borrões óbvios nas extremidades e sofre falhas ou distorções severas nas áreas não sobrepostas perante distorções de perspectiva elevadas. Em contrapartida, o método proposto pelo artigo conseguiu manter um alinhamento preciso e uma aparência natural em todos os cenários testados. Os autores apontam dois motivos principais para as atuais limitações do deep learning nesta área: primeiro, as restrições rigorosas à resolução das imagens de entrada (geralmente limitadas a tamanhos pequenos, como 128x128), o que causa inevitavelmente borrões e deformações nos resultados; segundo, a dependência inerente de modelos de treino supervisionados. Uma vez que não existem conjuntos de dados de treino reais com rótulos (labels) perfeitos para cenas reais com paralaxe, os modelos baseiam-se em imagens sintéticas, o que limita drasticamente o seu desempenho no mundo real e reafirma que as técnicas tradicionais de base geométrica continuam a ser a abordagem dominante (mainstream) no campo da costura de imagens.

4.2 Análise quantitativa

A análise quantitativa detalhada na Tabela 4.2 consolida a eficácia do método proposto ao medir o Erro Quadrático Médio (RMSE) do alinhamento em 14 conjuntos de imagens diferentes. Os dados numéricos evidenciam que a nova abordagem ("Ours") obteve consistentemente os menores valores de RMSE em absolutamente todos os cenários testados, indicando a maior precisão de alinhamento ao superar os métodos de Homografia Global, APAP, SPHP e AANAP. Nos primeiros nove casos, que são caracterizados por desafios de alta paralaxe, o baixo índice de erro do método proposto atesta que a etapa de pós-processamento elástico com TPS elimina efetivamente os desvios de projeção residuais que os outros métodos deixam passar. Por fim, nos cinco últimos cenários da tabela — que representam imagens com texturas fracas ou padrões repetitivos —, a pontuação expressivamente menor da nova abordagem comprova quantitativamente que a sua estratégia de registro (ORB+GMS) é muito superior à combinação clássica (SIFT+RANSAC) utilizada pelos concorrentes para encontrar pontos de correspondência corretos.

4.3 Avaliação da qualidade de alinhamento

Nesta avaliação, os autores realizam uma avaliação em etapas para isolar e comprovar a contribuição específica de duas das suas principais otimizações: o registro de imagens coarse-to-fine (ORB+GMS) e o pós-processamento de deformação com TPS. Utilizando o método AANAP como base teórica de comparação, os testes qualitativos demonstraram que apenas a introdução do registro avançado via GMS já reduz significativamente o efeito fantasma (ghosting), enquanto a adição subsequente do TPS atua eliminando por completo os desalinhamentos remanescentes nas emendas. Do ponto de vista quantitativo, a análise corrobora essa evolução: a adoção da estratégia ORB+GMS diminui o Erro Quadrático Médio (RMSE) ao fornecer um volume maior e mais preciso de correspondências (mesmo em áreas com texturas fracas), e a aplicação final da malha elástica (TPS) reduz o erro de forma ainda mais drástica em todos os casos avaliados. Em conjunto, esses experimentos comprovam que cada uma das etapas integradas é indispensável e altamente eficaz para melhorar a precisão do alinhamento final do mosaico.

Table 1 RMSE of each image pair for five comparison methods

Database	Global	APAP	SPHP	AANAP	Ours
<i>temple</i>	8.823	7.905	6.503	6.732	5.457
<i>garden</i>	27.668	25.296	19.584	19.023	14.586
<i>chessgirl</i>	7.523	6.987	5.253	5.993	5.916
<i>Cathedral</i>	7.854	6.069	14.663	6.962	6.273
<i>cabin</i>	14.484	13.209	12.929	8.823	6.936
<i>railtracks</i>	22.389	28.101	16.040	10.073	6.503
<i>theater</i>	6.299	5.304	9.869	4.157	3.596
<i>carpark</i>	16.550	13.235	10.991	9.894	6.936
<i>seagull-24</i>	8.976	8.109	5.483	6.758	6.222
<i>wall</i>	8.645	9.180	5.355	4.769	4.106
<i>building</i>	19.176	13.796	10.736	9.206	6.707
<i>tower</i>	24.761	19.431	9.920	13.082	7.115
<i>desk</i>	5.636	5.279	5.712	5.253	4.667
<i>worktable</i>	11.909	6.528	17.264	8.186	5.024

4.4 Comparação da eficiência computacional

O estudo demonstra que existe um equilíbrio entre o tempo de execução e a precisão do alinhamento. Métodos como o de aprendizagem profunda (DIS) e de corte de emenda (FARSE) são os mais rápidos, mas sacrificam severamente a qualidade da costura em cenas com alta paralaxe. Entre as técnicas de deformação espacialmente variável, a eficiência é inversamente proporcional à qualidade: o APAP é o mais rápido, seguido pelo SPHP e pelo AANAP. O método proposto pelos autores resulta no maior tempo de processamento entre todos os avaliados, pois, apesar de a etapa inicial de extração (ORB-GMS) ser mais rápida que o método clássico (SIFT-RANSAC), a aplicação da malha elástica de pós-processamento (TPS) exige um elevado custo computacional. Os autores concluem que a sua abordagem sacrifica intencionalmente a eficiência computacional em prol da máxima precisão, sendo a escolha ideal para aplicações que priorizam mosaicos de altíssima qualidade em detrimento do processamento em tempo real.

5 Conclusões

Para alcançar mosaicos panorâmicos de alta qualidade, a abordagem introduziu três melhorias centrais: uma estratégia de registro de pontos do "grosso para o fino"(garantindo correspondências mais precisas), uma etapa de pós-processamento de deformação elástica (para corrigir os vieses de projeção) e a integração de uma restrição de similaridade global (para evitar distorções de perspectiva). Embora os experimentos comprovem que o método alinha as imagens com a máxima precisão possível, os autores reconhecem suas limitações práticas: o algoritmo não tem um bom desempenho em cenários com oclusão severa e o seu tempo computacional é significativamente longo. Por conta disso, os trabalhos futuros focarão exatamente em resolver esses problemas de oclusão e em melhorar a eficiência computacional da ferramenta.

Referências

[1] SHI, Z. et al. Misalignment-eliminated warping image stitching method with grid-based motion statistics matching. *Multimedia Tools and Applications*, v. 81, p. 10723–10742, 2022. Disponível em: <<https://doi.org/10.1007/s11042-022-12064-2>>.